



**Politechnika
Śląska**

PRACA MAGISTERSKA

Zastosowanie metod sztucznej inteligencji do detekcji arytmii na podstawie
sygnałów PPG

Jakub KULA

Nr albumu: 296849

Kierunek: Informatyka

Specjalność: Internet i technologie sieciowe

PROWADZĄCY PRACĘ

dr hab. inż. Pander Tomasz, prof. PŚ

KATEDRA Cybernetyki, Nanotechnologii i Przetwarzania Danych

Wydział Automatyki, Elektroniki i Informatyki

Gliwice 2025

Tytuł pracy

Zastosowanie metod sztucznej inteligencji do detekcji arytmii na podstawie sygnałów PPG

Streszczenie

(Streszczenie pracy - odpowiednie pole w systemie APD powinno zawierać kopię tego streszczenia.)

Słowa kluczowe

(2-5 słów (fraz) kluczowych, oddzielonych przecinkami)

Thesis title

Application of artificial intelligence methods for arrhythmia detection based on PPG signal

Abstract

(Thesis abstract - to be copied into an appropriate field during an electronic submission - in English.)

Key words

(2-5 keywords, separated by commas)

Spis treści

1	Wstęp	1
1.1	Cel i zakres pracy	1
1.2	Aktualny stan wiedzy	1
1.3	Charakterystyka rozdziałów	1
2	Charakterystyka arytmii serca i sygnału PPG	3
2.1	Klasyfikacja i mechanizmy arytmii serca	3
2.1.1	Arytmie nadkomorowe	3
2.1.2	Arytmie komorowe	3
2.1.3	Migotanie przedsionków	3
2.2	Fotopletyzmografia - zasada działania i zastosowania	3
3	Metody uczenia maszynowego	5
3.1	Klasyczne metody	5
3.2	Sieci neuronowe	7
3.3	Miary jakościowe klasyfikatorów	8
3.4	Dobór modelu i optymalizacja hiperparametrów	9
4	Przetwarzanie i wybrane zbiory danych	11
4.1	Przegląd wykorzystanych zbiorów danych	11
4.1.1	MIMIC PERform AF Dataset	11
4.1.2	Zbiór PPG według Liu, Zengding i Zhou et al.	11
4.1.3	PhysioNet/CinC Challenge 2015	12
4.1.4	Dane syntetyczne	12
4.2	Przetwarzanie wstępne	13
4.3	Ekstrakcja cech	15
4.3.1	Cechy z domeny czasu	15
4.3.2	Cechy różnicowe	16
4.3.3	Cechy częstotliwościowe	17

5	Detekcja arytmii serca	19
5.1	Architektura i konfiguracja modeli	19
5.2	Walidacja wyników	19
5.2.1	Walidacja holdout	19
5.2.2	Walidacja K-Fold	19
5.3	Analiza wyników	19
6	Podsumowanie i wnioski	21
	Bibliografia	24
	Spis skrótów i symboli	27
	Lista dodatkowych plików, uzupełniających tekst pracy	29
	Spis rysunków	31
	Spis tabel	33

Rozdział 1

Wstęp

1.1 Cel i zakres pracy

1.2 Aktualny stan wiedzy

1.3 Charakterystyka rozdziałów

Rozdział 2

Charakterystyka arytmii serca i sygnału PPG

2.1 Klasyfikacja i mechanizmy arytmii serca

2.1.1 Arytmie nadkomorowe

2.1.2 Arytmie komorowe

2.1.3 Migotanie przedsionków

2.2 Fotopletyzmografia - zasada działania i zastosowania

Rozdział 3

Metody uczenia maszynowego

3.1 Klasyczne metody

- **Metoda najbliższych sąsiadów (KNN)** - klasyfikator opierający swoje predykcje na analizie k najbliższych sąsiadów ze zbioru treningowego. Metoda ta wykorzystuje metryki odległości do wyznaczenia próbek najbardziej zbliżonych do klasyfikowanego punktu, a następnie przypisuje mu etykietę tej klasy, która najczęściej występuje wśród wybranych k sąsiadów.

Najczęściej stosowaną metryką odległości jest odległość euklidesowa, zdefiniowana wzorem:

$$d(x, y) = \left(\sum_{i=1}^n |x_i - y_i|^2 \right)^{\frac{1}{2}} \quad (3.1)$$

gdzie $x = (x_1, x_2, \dots, x_n)$ oraz $y = (y_1, y_2, \dots, y_n)$ to dwa punkty w n -wymiarowej przestrzeni cech. Generalizacją odległości Euklidesowej jest odległości Minkowskiego zdefiniowana jako:

$$d(x, y) = \left(\sum_{i=1}^n |x_i - y_i|^q \right)^{\frac{1}{q}} \quad (3.2)$$

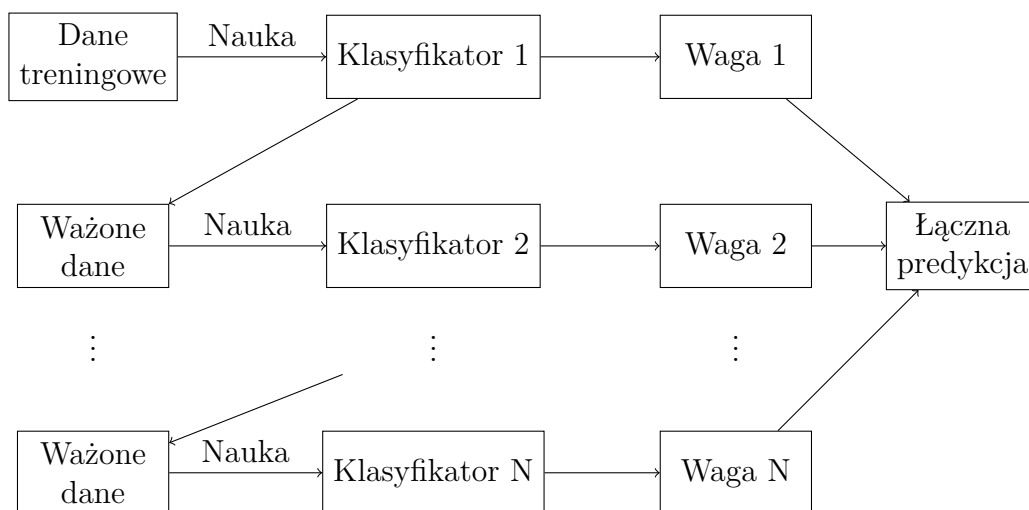
gdzie $q > 0$ [6]. Można zauważyć, że dla $q=2$ otrzymuje odległość Euklidesową, a dla $q=1$ odległość Manhattan. Ze względu na to, że algorytm KNN opiera się na obliczaniu odległości między próbkami, istotne jest zachowanie jednolitej skali cech. W przypadku, gdy poszczególne cechy mają różne zakresy wartości, cecha o największej rozpiętości może zdominować obliczenia odległości, a tym samym nieproporcjonalnie wpłynąć na wynik predykcji.

W przypadku tego klasyfikatora kluczowe jest odpowiednie dobranie liczby sąsiadów. Zbyt mała wartość parametru k może prowadzić do przeuczenia, w którym model nadmiernie dopasowuje się do danych treningowych i traci zdolność generalizacji. Z kolei zbyt duża liczba sąsiadów skutkuje zjawiskiem niedouczenia, w którym model nie jest w stanie uchwycić istotnych zależności w danych, przez co jego dokładność

również spada.[5].

- **Drzewo decyzyjne** -
- **Las losowy** -
- **Naiwny klasyfikator Bayesa** -
- **LLSVM** -
- **Modele typu Boosting** - koncepcja polegająca na połączeniu wielu modeli posiadających małą skuteczność w celu stworzenia jednego modelu o dużej dokładności[12, 4]. W ogólnym przypadku schemat działania boostingu polega na sekwencyjnym uczeniu modeli, gdzie każdy kolejny model otrzymuje informację o błędach popełnionych przez poprzednie i na tej podstawie stara się poprawić jakość predykcji całego systemu.

Rysunek 3.1: Schemat przetwarznia wstępnego



Największą wadą boostingu jest wysokie ryzyko przeuczenia, wynikające z jego mechanizmu uczenia się na błędach. Takie podejście sprzyja nadmiernemu skupianiu się na przykładach trudnych do sklasyfikowania, co może prowadzić do zbyt mocnego dopasowania modelu do danych treningowych i utraty zdolności generalizacji.

Zdecydowano się na wybór trzech modeli typu boosting, opartych na technice *Gradient Boosting*, czyli metodzie polegającej na sekwencyjnym minimalizowaniu funkcji straty poprzednich modeli przy użyciu algorytmu spadku gradientowego. Wybrane modele:

- XGBoost - wykorzystuje modele drzew decyzyjnych, w każdej iteracji dodając kolejne drzewo, które uczy się na podstawie błędów poprzednich. W celu minimalizacji funkcji straty stosowane jest rozwinięcie Taylora drugiego rzędu, a także regularyzacja L1 i L2 w celu zapobiegania przeuczeniu.

- CatBoost - podobnie jak XGBoost opiera się na drzewach decyzyjnych i metodzie gradient boosting, jednak dodatkowo optymalizuje przetwarzanie cech kategorycznych i zmniejsza ryzyko przeuczenia wprowadzając mechanizm uporządkowane wzmocnienie
- LightBoost - również bazuje na drzewach decyzyjnych, jednak w procesie uczenia nie tworzy całych nowych drzew, lecz rozwija istniejące liście tych drzew, które posiadają najwyższą wartość funkcji straty.


3.2 Sieci neuronowe

3.3 Miary jakościowe klasyfikatorów

w przypadku klasyfikacji binarnej jesteśmy w stanie wyznaczyć 4 możliwe przypadki:

- **True Positive (TP)** - poprawna klasyfikacja przypadku z arytmia serca jako przypadek chorobowy.
- **False Positive (FP)** - błędna klasyfikacja przypadku zdrowego jako przypadek z arytmia. Nazywana również błędem pierwszego rodzaju.
- **True Negative (TN)** - poprawna klasyfikacja przypadku zdrowego jako niechorobowego.
- **False Negative (FN)** - błędna klasyfikacja przypadku z arytmia jako przypadek zdrowy. Nazywana również błędem drugiego rodzaju.

Dzięki wyznaczeniu 4 przypadków, jesteśmy w stanie w graficzny sposób przedstawić wyniki klasyfikacji w postaci macierzy pomyłek.



Rysunek 3.2: Struktura macierzy pomyłek dla klasyfikacji binarnej

Wykorzystując wymieniane przypadki, jesteśmy w stanie wyznaczyć metryki jakościowe, które pozwalają na ocenę skuteczności klasyfikatora.

- **Dokładność** - metryka określająca jaki procent przypadków został poprawnie sklasyfikowany. Jest to metryka która jest mocno zależna od rozkładu klasy. W sytuacji gdy jedna klasa jest znacznie liczniejsza, może ona mocno zakrzywić wyniki. W przypadku klasyfikacji binarnej możemy ją wyznaczyć jako:

$$\text{Accuracy} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{FP} + \text{TN} + \text{FN}} \quad (3.3)$$

- **Precyzja** - miara jakościowa określająca jaki procent przypadków sklasyfikowanych jako osoby z chorobą rzeczywiście posiadają arytmie. Precyzja nie zwraca uwagi na przypadki zdrowe, zwraca uwagę jedynie na przypadki z arytmią. Omawianą miarę możemy obliczyć jako:

$$\text{Precision} = \frac{TP}{TP + FP} \quad (3.4)$$

- **Czułość** - prawdopodobieństwo że klasyfikacja będzie poprawna pod warunkiem że dana próbka pochodzi od osoby chorej. Można ją obliczyć ze wzoru:

$$\text{Recall} = \frac{TP}{TP + FN} \quad (3.5)$$

- **F-miara** - metryka która łączy precyzję i czułość. Wyznacza się jako średnią harmoniczną owych metryk. Ze względu na to, jest ona bardzo wrażliwa na przypadki gdy jedna z metryk jest bardzo niska. Jednak jest ona odporna na nierówny rozkład klas. Wartość F-miary możemy wyznaczyć jako:

$$F_1 = \frac{1}{2} \left(\frac{1}{\text{precision}} + \frac{1}{\text{recall}} \right) = \frac{2 \cdot \text{precision} \cdot \text{recall}}{\text{precision} + \text{recall}} = \frac{2TP}{2TP + FP + FN} \quad (3.6)$$

- **Matthews Correlation Coefficient (MCC)** - miara korelacji binarnej wprowadzona do uczenia maszynowego przez Briana W. Matthews [8]. Zakres tego współczynnika wynosi od -1 do 1 , gdzie 1 oznacza perfekcyjną klasyfikację, 0 klasyfikację losową, a -1 - całkowicie odwrotną predykcję. MCC jest wskaźnikiem jakościowym odpornym na niezbalansowanie klas i można go obliczyć według wzoru:

$$\text{MCC} = \frac{TP \cdot TN - FP \cdot FN}{\sqrt{(TP + FP)(TP + FN)(TN + FP)(TN + FN)}} \quad (3.7)$$

3.4 Dobór modelu i optymalizacja hiperparametrów

Rozdział 4

Przetwarzanie i wybrane zbiory danych

4.1 Przegląd wykorzystanych zbiorów danych

TODO - napisać coś tutaj

4.1.1 MIMIC PERform AF Dataset

Zbiór danych MIMIC PERform AF[9] został pozyskany z bazy MIMIC-III Waveform Database Matched Subset[10]. Zawiera on 20-minutowe zapisy sygnałów fotopletyzmo-
graficznych oraz elektrokardiograficznych, zarejestrowane u 35 ciężko chorych dorosłych
pacjentów hospitalizowanych na oddziałach intensywnej terapii. U 19 z tych pacjentów
zdiagnozowano migotanie przedsionków, natomiast u pozostałych zapis sygnałów nie wy-
kazywał nieprawidłowości w rytmie serca. Dane zostały zebrane z wykorzystaniem moni-
tora przyłóżkowego, z częstotliwością próbkowania wynoszącą 125 Hz.

4.1.2 Zbiór PPG według Liu, Zengding i Zhou et al.

Dane wykorzystywane w tym zbiorze[7] zostały zebrane w okresie od marca 2020 do
marca 2021 w szpitalu Fuwai w Pekinie, będącym wyspecjalizowaną placówką w zakresie
chorób sercowo-naczyniowych. Sygnał fotopletyzmograficzny został początkowo próbko-
wany z częstotliwością 250 Hz, a następnie poddany procesowi resamplingu do 100 Hz. W
celu usunięcia niepożądanych zakłóceń zastosowano filtrację pasmową w zakresie 0.5 - 50
Hz. Przefiltrowany sygnał został następnie podzielony na segmenty 10-sekundowe, przy-
czym fragmenty zawierające istotne zakłócenia zostały odrzucone.

Cały zbiór danych obejmuje zapisy od 228 pacjentów, co odpowiada łącznie 118 217
segmentom 10-sekundowym. Na potrzeby badań publicznych udostępniono jedynie 46 827
z tych fragmentów. Dane zostały skategoryzowane według pięciu typów arytmii: przed-

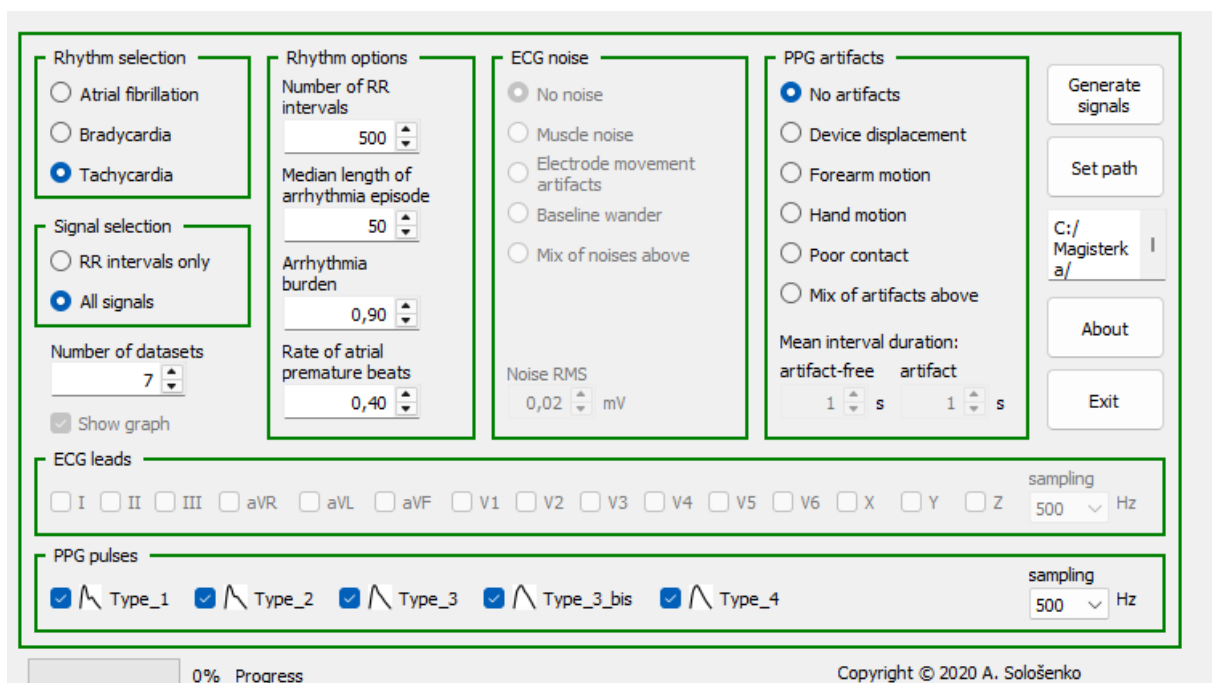
wczesny skurcz komorowy, przedwczesny skurcz przedsionkowy, tachykardia komorowa, tachykardia nadkomorowa oraz migotanie przedsionków.

4.1.3 PhysioNet/CinC Challenge 2015

test[1] Jest zbiorem użytym w konkursie mającym na celu stworzenie algorytmu redukującego ilość fałszywych alarmów podczas detekcji arytmii serca. Dane pochodzą z czterech losowo wybranych, szpitali w Stanach Zjednoczonych oraz Europie. Udostępniona część zbioru zawiera 750 nagrań. Sygnały zostały próbkowane z częstotliwością 250Hz oraz przefiltrowane filtrem pasmowym 0.05 - 40Hz

4.1.4 Dane syntetyczne

W celu wzbogacenia zbiorów danych, zdecydowano użyć się danych syntetycznych wygenerowanych przy użyciu generatora sygnałów PPG i ECG z epizodami arytmii[11]. Zastosowany symulator umożliwia pełną kontrolę nad procesem generowania sygnałów. Użytkownik ma możliwość definiowania szeregu parametrów determinujących charakterystykę sygnału, w tym: rodzaj arytmii, mediane długości epizodów arytmii, obciążenie arytmią które determinuje łączny czas kiedy występuje arytmia, wskaźnik przedwczesnych skurczów przedsionkowych czy rodzaj pulsu zdefiniowany przez Dawber et al[2].



Rysunek 4.1: GUI użytego symulatora

W ramach eksperymentu wygenerowano pięć syntetycznych podzbiorów danych, z których każdy został zasymulowany z częstotliwością próbkowania równą 500 Hz oraz

zawierał sygnały odpowiadające 500 kolejnym interwałom RR. Każdy ze zbiorów zawierał równą ilość przypadków bradycardii, tachycardii i migotania przedsionków. Zawierał się w nich także każdy rodzaj pulsu PPG. Zdecydowano się nie wykorzystywać możliwości generowania sygnałów z szumem.

Poszczególne podzbiory różniły się parametrami charakterystycznymi dla przebiegu arytmii:

Tabela 4.1: Porównanie parametrów podzbiorów danych syntetycznych

Zbiór	Mediana długości epizodu arytmii	Obciążenie arytmią	Wskaźnik przedwczesnych skurczów przedsionkowych
1	3	0.1	0.05
2	10	0.3	0.10
3	5	0.5	0.10
4	30	0.4	0.20
5	50	0.9	0.40

Każdy ze zbiorów ma symulować inny rodzaj arytmii:

- Zbiór 1 - Rzadkie występowanie krótkich epizodów arytmii
- Zbiór 2 - Umiarkowane występowanie z umiarkowaną liczbą przedwczesnych skórczy
- Zbiór 3 - Wysokie występowanie arytmii z krótkimi epizodami
- Zbiór 4 - Długie, częste epizody arytmii.
- Zbiór 5 - Niemal ciągła arytmia

Dzięki zastosowanemu symulatorowi, wygenerowane dane syntetyczne mogą stanowić cenne źródło informacji dla przyszłych modeli klasyfikacyjnych. Umożliwiają one nie tylko lepsze zrozumienie przypadków odstających, ale również wspierają proces uczenia modeli w scenariuszach bardziej typowych, odpowiadających klasycznym przypadkom klinicznym.

4.2 Przetwarzanie wstępne

Pomimo wysokiej jakości wybranych zbiorów danych, ich bezpośrednie wykorzystanie w procesie klasyfikacji wymaga zastosowania wieloetapowego przetwarzania wstępnego. Głównym celem tych transformacji jest ujednolicenie charakterystyki sygnałów pochodzących z różnych źródeł oraz przygotowanie reprezentatywnego wektora cech, który może zostać wykorzystany w procesie uczenia klasyfikatorów.

Pierwszym etapem przetwarzania wstępnego sygnału jest jego filtracja. W tym celu zastosowano filtr pasmowo-przepustowy o częstotliwościach granicznych 0.5 Hz oraz 40 Hz. Głównym celem tak dobranego filtra jest eliminacja zakłóceń pochodzących spoza pasma istotnego z punktu widzenia analizy sygnałów PPG. Dolne ograniczenie pozwala zmniejszyć wpływ ruchu pacjenta czy zmianę położenia czujnika, natomiast górna granica redukuje wpływ wysokoczęstotliwościowych zakłóceń, takich jak zakłócenia elektromagnetyczne.

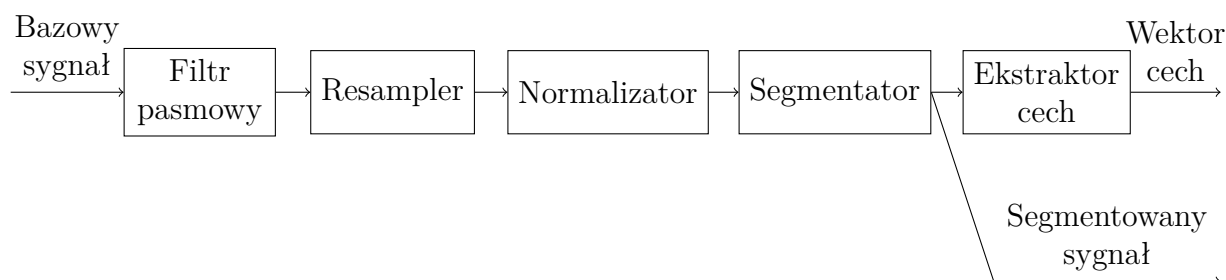
Drugim istotnym etapem przetwarzania wstępnego była zmiana częstotliwości próbkowania sygnałów. Zdecydowano się na jednolitą częstotliwość 100 Hz, co odpowiada najniższej wartości występującej wśród wykorzystanych zbiorów danych. Ujednolicenie próbkowania do tej wartości niesie ze sobą kilka korzyści. Po pierwsze, redukcja liczby próbek skutkuje zmniejszeniem rozmiaru danych, co przekłada się na krótszy czas ich przetwarzania jak i nauki modeli w sposób bezcechowych.

Kolejnym krokiem w procesie przetwarzania wstępnego była normalizacja sygnału do przedziału $[0, 1]$. Wykorzystane zbiory danych charakteryzowały się zróżnicowanym zakresem wartości amplitud, co mogłoby negatywnie wpłynąć zarówno na proces uczenia cechowego, jak i bezcechowego. Niejednorodna skala danych może prowadzić do dominacji niektórych sygnałów lub cech w trakcie uczenia. W celu minimalizacji tego efektu, zdecydowano się na niezależną normalizację każdego sygnału osobno.

Z uwagi na fakt, że zbiór danych opracowany przez Liu, Zengding i Zhou et al.[7] składa się z 10-sekundowych segmentów sygnału, zdecydowano o ujednoliceniu długości wszystkich pozostałych próbek poprzez ich podział na fragmenty o identycznym czasie trwania. Segmentacja została przeprowadzona po wcześniejszym przeskalowaniu częstotliwości próbkowania do 100 Hz, co oznacza, że każdy 10-sekundowy segment zawiera dokładnie 1000 próbek. Próbki te, zostaną wykorzystane do bezcechowej nauki klasyfikatorów.

Ostatnim etapem przetwarzania wstępnego jest wybranie oraz ekstrakcja cech. Proces ten zostanie omówiony dokładnie w rozdziale 4.3

Rysunek 4.2: Schemat przetwarznia wstępnego



4.3 Ekstrakcja cech

Zdecydowano się na wybór czterech głównych domen analizy, z których każda interpretuje sygnał PPG z innej perspektywy, umożliwiając wydobycie zróżnicowanych informacji. Niezależnie od wybranej domeny, we wszystkich przypadkach zastosowano zestaw podstawowych miar statystycznych, które zostały wyekstrahowane z przekształconych sygnałów:

- Średnia arytmetyczna,
- Mediana,
- Odchylenie standardowe,
- Wariancja,
- Rozstęp międzykwartylowy,

4.3.1 Cechy z domeny czasu

Pierwszą z wybranych domen, interpretuje sygnał jako funkcję ciągłą w czasie. Domena czasu traktuje kolejne próbki czasowe jako kolejne wartości funkcji amplitudy. Domena ta bezpośrednio analizuje sygnał w jej pierwotnej postaci, gdzie $x = \{x_1, x_2, \dots, x_n\}$. W tej przestrzeni, zdecydowano się na wybranie następujących cech:

- **Skośność** - miara asymetrii sygnału:

$$\frac{1}{N} \sum_{i=1}^N \left(\frac{x_i - \bar{x}}{\sigma} \right)^3 \quad (4.1)$$

gdzie:

- \bar{x} - średnia arytmetyczna.
- σ - odchylenie standardowe sygnału.

- **Współczynnik zmienności** - względna miara zróżnicowania sygnału:

$$CV = \frac{\sigma}{\bar{x}} \quad (4.2)$$

- **Średnie odchylenie bezwzględne** - bezwzględna miara zróżnicowania sygnału:

$$\text{MAD} = \frac{1}{n} \sum_{i=1}^n |x_i - \bar{x}| \quad (4.3)$$

- **Entropia Shannona** - miara niepewności sygnału:

$$H = - \sum_{i=1}^N p_i \log_2 p_i \quad (4.4)$$

gdzie:

- p_i - prawdopodobieństwo wystąpienia i -tej wartości sygnału.

4.3.2 Cechy różnicowe

Kolejną z wybranych domen jest domena cech różnicowych, w której sygnał nie jest bezpośrednio intereptowany jako kolejne wartości amplitudy, tylko poprzez różnice zmian między kolejnymi próbkami $\Delta x = \{x_2 - x_1, x_3 - x_2, \dots, x_n - x_{n-1}\}$. Cechy wyekstrahowane z tej domeny:

- **Procent dodatnich różnic** - odsetek dodatkich różnic kolejnych wartości sygnału

$$\frac{100}{N-1} \sum_{i=1}^{N-1} \delta(\Delta x > 0) \quad (4.5)$$

gdzie:

- $\delta(\cdot)$ - funkcja wskaźnikowa, równa 1 gdy warunek jest spełniony, 0 w przeciwnym wypadku.

- **Średnia wartość bezwzględna różnic:**

$$\frac{1}{N-1} \sum_{i=1}^{N-1} |\Delta x| \quad (4.6)$$

- **Pierwiastek średniokwadratowy różnic** - miara zmienności rytmu serca, która odzwierciedla aktywność układu przywspółczulnego:[3]

$$\text{RMSSD} = \sqrt{\frac{1}{N-1} \sum_{i=1}^{N-1} (\Delta x)^2} \quad (4.7)$$

- **Znormalizowane średnie odchylenie bezwzględne różnic** - ocenia lokalną dynamikę zmian sygnału:

$$\frac{1}{N-1} \sum_{i=1}^{N-1} \frac{|\Delta x|}{\bar{x}} \quad (4.8)$$

- **Znormalizowana suma bezwzględnych różnic:**

$$\frac{\sum_{i=1}^{N-1} |\Delta x|}{\sum_{i=1}^N |x_i|} \quad (4.9)$$

4.3.3 Cechy częstotliwościowe

Ostatnią wybraną domeną jest domena częstotliwościowa. W tej domenie, sygnał jest przekształcany przy użyciu transformaty Fouriera, aby uzyskać jego rozkład mocny w zależności częstotliwości $P_{xx}(f)$, gdzie f oznacza częstotliwość. Analiza cech częstotliwościowych, pozwala identyfikować składowe dominujące jak i nieregularności. W tej domenie zdecydowano się na ekstrakcję następujących cech:

- **Maksymalny szczyt widmowy**

$$f_{\max} = f\left(\arg \max_f P_{xx}(f)\right) \quad (4.10)$$

- **Kurtoza widma** - spłaszczenie sygnału:

$$\text{kurt}(P_{xx}) = \frac{1}{M} \sum_{j=1}^M \left(\frac{P_{xx}(f_j) - \overline{P_{xx}}}{\sigma_{P_{xx}}} \right)^4 \quad (4.11)$$

- **Udział wysokich szczytów widma**

$$\frac{\sum_{j=1}^M \delta(P_{xx}(f_j) > \overline{P_{xx}})}{M} \quad (4.12)$$

Rozdział 5

Detekcja arytmii serca

5.1 Architektura i konfiguracja modeli

5.2 Walidacja wyników

5.2.1 Walidacja holdout

5.2.2 Walidacja K-Fold

5.3 Analiza wyników

Rozdział 6

Podsumowanie i wnioski

- syntetyczny opis wykonanych prac
- wnioski
- możliwość rozwoju, kontynuacji prac, potencjalne nowe kierunki
- Czy cel pracy zrealizowany?

Bibliografia

- [1] Gari D. Clifford, Ikaro Silva, Benjamin Moody, Chengyu Liu i Roger G. Mark. *PhysioNet/Computing in Cardiology Challenge 2015: Reducing False Arrhythmia Alarms in the ICU*. <https://archive.physionet.org/challenge/2015/>. Accessed July 2025. Dataset provided as part of the PhysioNet/CinC Challenge 2015. 2015.
- [2] Thomas R. Dawber, H. E. Thomas i P. M. Mcnamara. „Characteristics of the diastolic notch of the arterial pulse wave in coronary heart disease”. W: *Angiology* 24.4 (1973), s. 244–255. DOI: 10.1177/000331977302400407.
- [3] Maryam Farokhipour i Farzaneh Ketabchi. „The Validity of Heart Rate Variability Obtained from Electrocardiography and Blood Pressure in Rats Subjected to Isoproterenol-Induced Heart Ischemia”. W: *Journal of Tehran University Heart Center* 18.1 (sty. 2023), s. 33–38. DOI: 10.18502/jthc.v18i1.12579. URL: <https://doi.org/10.18502/jthc.v18i1.12579>.
- [4] Michael Kearns i Leslie Valiant. „Cryptographic Limitations on Learning Boolean Formulae and Finite Automata”. W: *Proceedings of the Twenty-First Annual ACM Symposium on Theory of Computing*. 1989.
- [5] Max Kuhn i Kjell Johnson. *Applied Predictive Modeling*. Springer, 2013.
- [6] Bing Liu. *Web Data Mining*. Springer Berlin / Heidelberg, 2007.
- [7] Zengding Liu, Bin Zhou, Zhiming Jiang, Xi Chen, Ye Li, Min Tang i Fen Miao. „Multiclass Arrhythmia Detection and Classification From Photoplethysmography Signals Using a Deep Convolutional Neural Network”. W: *Journal of the American Heart Association* 11.7 (2022), e023555.
- [8] B. W. Matthews. „Comparison of the Predicted and Observed Secondary Structure of T4 Phage Lysozyme”. W: *Biochimica et Biophysica Acta (BBA) - Protein Structure* 405.2 (1975), s. 442–451. DOI: 10.1016/0005-2795(75)90109-9.
- [9] MIMIC PERform AF Dataset contributors. *MIMIC PERform AF Dataset*. <https://physionet.org/content/mimic-perform-af/>. 2020.

- [10] Benjamin Moody, George Moody, Mauricio Villarroel, Gari D. Clifford i Ikaro Silva. *MIMIC-III Waveform Database Matched Subset*. <https://physionet.org/content/mimic3wdb-matched/1.0/>. Wer. 1.0. Published: April 7, 2020. 2020.
- [11] A. Solosenko, A. Petrenas, B. Paliakaite, V. Marozas i L. Sornmo. *Model for Simulating ECG and PPG Signals with Arrhythmia Episodes*. 2022. DOI: 10.13026/s32e-sv15. URL: <https://doi.org/10.13026/s32e-sv15>.
- [12] Leslie Valiant. „A Theory of the Learnable”. W: *Communications of the ACM* 27 (1984), s. 1134–1142.

Dodatki

Spis skrótów i symboli

PPG Sygnał fotopletyzmograficzny

\bar{x} Średnia wartość sygnału

σ Odchylenie standardowe

H Entropie Shannona

E Energia

RMSSD Pierwiastek średniokwadratowy różnic

kurt Kurtoza widma

MVC model – widok – kontroler (ang. *model-view-controller*)

μ stopnień przyleżności do zbioru

\mathbb{E} zbiór krawędzi grafu

\mathcal{L} transformata Laplace’a

Lista dodatkowych plików, uzupełniających tekst pracy

W systemie do pracy dołączono dodatkowe pliki zawierające:

- źródła programu,
- zbiory danych użyte w eksperymentach,
- film pokazujący działanie opracowanego oprogramowania lub zaprojektowanego i wykonanego urządzenia,
- itp.

Spis rysunków

3.1	Schemat przetwarznia wstępnego	6
3.2	Struktura macierzy pomyłek dla klasyfikacji binarnej	8
4.1	GUI użytego symulatora	12
4.2	Schemat przetwarznia wstępnego	15

Spis tabel

4.1	Porównanie parametrów podzbiorów danych syntetycznych	13
-----	---	----